1. Indikator Ketercapaian (Level C4)

1. **Mendiagnosis Karakteristik Data:** Mahasiswa mampu mengurai struktur dataset, membedah tipe variabel (*nominal*, *ordinal*, *interval*, *ratio*), serta memeriksa integritas data (*missing values*, duplikasi).
2. **Mendeteksi dan Membedah Anomali:** Mahasiswa mampu menganalisis keberadaan *outliers* menggunakan metode statistik parametrik (Z-Score) dan non-parametrik (*Interquartile Range* / IQR).
3. **Menganalisis Pola dan Korelasi:** Mahasiswa mampu mengurai hubungan multivariat, mengidentifikasi multikolinearitas antarfitur menggunakan matriks korelasi, dan menafsirkan visualisasi sebaran data secara kritis.

2. Struktur Materi Pembelajaran

A. Fondasi Analitis EDA

- **Tujuan EDA:** Memvalidasi asumsi awal, menguji hipotesis distribusi fitur, dan menentukan strategi *data preprocessing* yang tepat.
- **Inspeksi Holistik:** Membedah dimensi, ringkasan statistik 5-angka (*five-number summary*), serta ketidakseimbangan tipe data numerik vs. kategorikal.

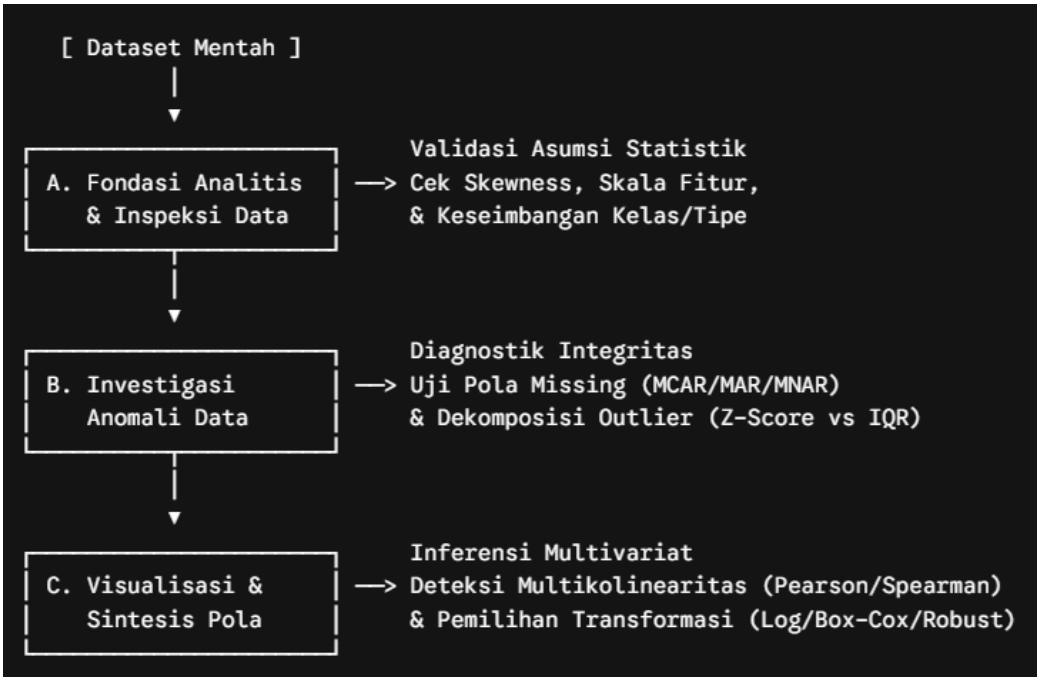
B. Investigasi Anomali Data

- Missing Value Analysis:
    - Pola hilangnya data: *Missing Completely at Random* (MCAR), *Missing at Random* (MAR), dan *Missing Not at Random* (MNAR).
    - Dampak analitis: Menilai risiko bias estimasi jika data dibuang (*deletion*) vs. diisi (*imputation*).
- Deteksi Outliers:
    - Pendekatan IQR (Tukey's Fences): Q1 - 1,5 x IQR hingga Q3 + 1,5 x IQR.
    - Pendekatan Z-score: Ambang batas $|Z| > 3$ untuk data terdistribusi normal.
    - Analisis konteks: Membedakan antara *noise/error input* dengan *natural variability* (misal: kasus *fraud detection*).

C. Visualisasi Data untuk Penarikan Kesimpulan

- **Univariat:** Analisis *skewness* dan *kurtosis* menggunakan histogram dan KDE (*Kernel Density Estimation*).
- **Bivariat:** Membedah asosiasi fitur kontinu vs. label target via *box plot* / *violin plot*.
- **Multivariat:** *Heatmap* korelasi (Pearson vs. Spearman) untuk deteksi redundansi fitur (*multicollinearity*).

ALUR INVESTIGASI EDA



A. Fondasi Analitis EDA

Exploratory Data Analysis (EDA) pada level C4 bukan sekadar mengeksekusi perintah sintaks dasar, melainkan proses diagnostik sistematis untuk memvalidasi apakah data memenuhi prasyarat matematis algoritma pembelajaran mesin.

1. Tujuan Analitis EDA

- **Validasi Asumsi Algoritmik:**
    - Algoritma parametrik linear (Linear Regression, Logistic Regression, Linear Discriminant Analysis) mengasumsikan residu terdistribusi normal (*homoscedasticity*) dan hubungan linear antarvariabel. EDA berfungsi mendeteksi pelanggaran asumsi ini sejak dini.
    - Algoritma berbasis jarak (*distance-based*) seperti K-Nearest Neighbors (KNN), Support Vector Machines (SVM), dan K-Means sangat rentan terhadap magnitudo skala fitur. EDA mengidentifikasi disparitas variansi antarfitur untuk menentukan kebutuhan *scaling* (StandardScaler vs. MinMaxScaler).
    - Algoritma berbasis pohon keputusan (*tree-based*) seperti Random Forest dan XGBoost bersifat *scale-invariant*, namun tetap sensitif terhadap representasi nilai kategorikal berkardinalitas tinggi (*high-cardinality features*).
- **Penentuan Strategi Preprocessing Berbasis Bukti:**
    - Mencegah kesalahan fatal dalam *pipeline* (seperti melakukan standardisasi Z-score pada data yang memiliki pencilan ekstrem atau

distribusi multivariat bimodal).

2. Inspeksi Holistik & Dekonstruksi Struktur Data

- **Analisis Dimensi & Sparsitas:**
  - Mengevaluasi rasio jumlah observasi (N) terhadap jumlah fitur (p). Jika p >> N, analis harus mengantisipasi fenomena *Curse of Dimensionality* yang menuntut reduksi dimensi (PCA atau seleksi fitur).
  - Menghitung tingkat sparsitas matriks data:
    Sparsity = 1 - (Jumlah Elemen Non-Zero / (N × p))
- **Dekonstruksi Ringkasan Statistik 5-Angka (*Five-Number Summary*):**
  - Terdiri dari: Minimum, Q_1 (Persentil 25), Q_2 (Median / Persentil 50), Q_3 (Persentil 75), Maksimum.
  - **Analisis Komparasi Mean vs. Median:**
    - Mean ≈ Median: Distribusi mendekati simetris (Gaussian).
    - Mean > Median: Distribusi menceng ke kanan (*right-skewed / positive skew*). Median menjadi estimasi tendensi sentral yang lebih reliabel dibanding mean.
    - Mean < Median: Distribusi menceng ke kiri (*left-skewed / negative skew*).
- **Investigasi Ketidakseimbangan (*Imbalance Analysis*):**
  - **Variabel Kategorikal:** Mengidentifikasi dominasi frekuensi absolut dan relatif kelas target. Menghitung rasio ketidakseimbangan kelas (*imbalance ratio*), misal 99:1 pada kasus deteksi penipuan (*fraud*), yang mengindikasikan bahwa metrik *Accuracy* akan menjadi metrik palsu (*accuracy paradox*) sehingga memerlukan metrik F1-Score atau PR-AUC.
  - **Kardinalitas Fitur:** Memeriksa fitur dengan kardinalitas ekstrem (misal ID unik dengan kardinalitas mendekati N, atau fitur biner seragam dengan variansi mendekati nol). Fitur dengan variansi nol wajib dieliminasi via *Variance Thresholding*.

B. Investigasi Anomali Data

Diagnostik terhadap anomali bertujuan memastikan integritas inferensi statistik dan mencegah degradasi performa model (*bias-variance tradeoff*).

1. Analisis Mekanisme Hilangnya Data (*Missing Value Mechanisms*)

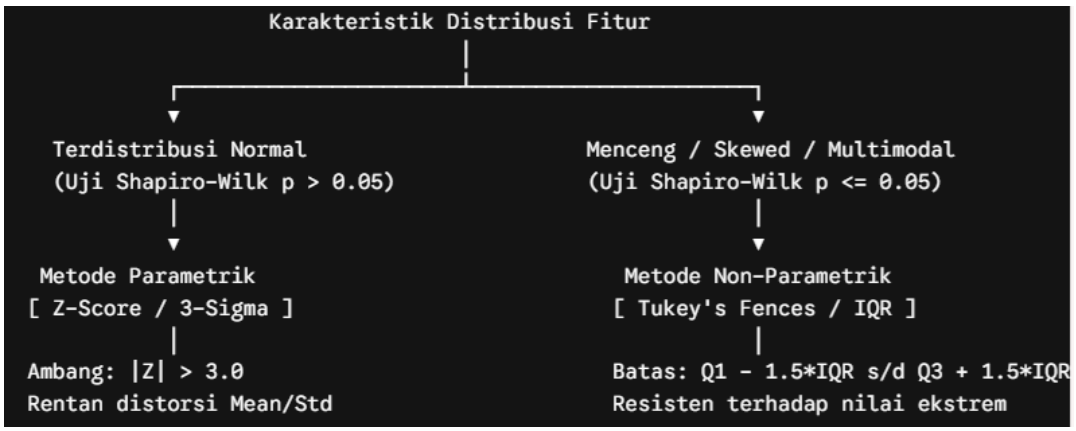
Tipe Missing	**Definisi Matematis & Logika**	**Contoh Kasus Nyata**	**Dampak & Strategi Penanganan**

MCAR (*Missing Completely at Random*)	Probabilitas data hilang tidak bergantung pada nilai variabel itu sendiri maupun variabel lain: P(Y_miss | Y_obs, Y_miss) = P(Y_miss)	Sensor IoT mati mendadak karena kehabisan baterai secara acak; kuesioner terhapus karena galat server acak.	**Dampak:** Mengurangi kekuatan uji statistik (*power of test*), namun tidak menimbulkan bias sistematis. **Strategi:** Penghapusan baris (*Listwise Deletion*) masih dapat dibenarkan jika proporsi hilang < 5%. Imputasi *mean/median* relatif aman.
MAR (*Missing at Random*)	Probabilitas hilangnya data bergantung secara sistematis pada variabel teramati lain, bukan nilai variabel itu sendiri: P(Y_miss | Y_obs, Y_miss) = P(Y_miss | Y_obs)	Data pendapatan (*income*) lebih sering kosong pada kelompok usia muda/mahasiswa dibanding kelompok usia mapan.	**Dampak:** *Deletion* akan mendistorsi sampel dan menghasilkan estimasi yang bias. **Strategi:** Imputasi berbasis model bersyarat seperti *K-Nearest Neighbors (KNN) Imputation* atau *Multiple Imputation by Chained*

			Equations (MICE).
MNAR (*Missing Not at Random*)	Probabilitas hilangnya data secara langsung berkorelasi dengan nilai tak teramati dari fitur tersebut: P(Y_miss | Y_obs, Y_miss) ≠ P(Y_miss | Y_obs)	Pasien dengan kondisi depresi sangat parah menolak mengisi kuisioner evaluasi mental; orang berpenghasilan sangat tinggi menolak menulis nominal gaji.	**Dampak:** Menyebabkan bias struktural berat pada model. **Strategi:** Nilai kosong harus dipertahankan sebagai sinyal informasi. Buat fitur indikator biner (*missing indicator feature*, misal X_isnan ∈ {0, 1}) sebelum melakukan imputasi domain-spesifik..

2. Dekonstruksi dan Deteksi Outlier

Analis level C4 harus membedakan secara kritis kapan menggunakan pendekatan parametrik versus non-parametrik.



- **Pendekatan Non-Parametrik: Tukey's Fences (Metode IQR)**
  - **Perumusan:**
    IQR = Q3 - Q1
    Batas Bawah = Q1 - 1,5 x IQR ; Batas Atas = Q3 + 1,5 x IQR
  - **Dasar Teoretis:** Menggunakan ukuran posisi (kuartil) yang resisten terhadap pencilan ekstrem (*breakdown point* 25%).
  - **Kelebihan:** Sangat adaptif untuk data asimetris (*skewed data*), distribusi eksponensial, log-normal, atau data berdimensi pendapatan/finansial.
  - **Pencilan Ekstrem (*Extreme Outliers*):** Didefinisikan menggunakan pengali 3,0 x IQR.
- **Pendekatan Parametrik: Standarisasi Skor Z (*Z-Score / 3-Sigma Rule*)**
  - **Perumusan:**
    Z = (x - μ) / σ
    Kondisi anomali: |Z| > 3,0 (berada di luar 99,73% sebaran Gaussian ideal).
  - **Kelemahan Mendasar (*Masking Effect*):** Nilai μ (*mean*) dan σ (*standar deviasi*) itu sendiri terdistorsi oleh keberadaan pencilan ekstrem.
  - **Solusi Lanjutan (Modified Z-Score via MAD):** Menggunakan *Median Absolute Deviation*:
    M_i = [0,6745 x (x_i - x_median)] / MAD di mana MAD = median(|x_i - x_median|)
    Ambang batas: |M_i| > 3,5.
- **Analisis Konteks: Error vs. Valid Information:**
  - **Noise / Data Entry Error:** Nilai di luar batas logika fisika/sistem (contoh: Usia = 999, Suhu Manusia = 150°C, Tekanan Darah < 0). **Tindakan:** Hapus baris atau ubah menjadi NaN lalu imputasi.
  - **Natural Variability / Novelty Sinyal:** Nilai riil ekstrem yang membawa informasi kritis (contoh: Volume transaksi kartu kredit Rp150.000.000

pada akun yang rata-rata bertransaksi Rp200.000). **Tindakan:** Jangan dibuang. Gunakan algoritma berbasis pohon yang kebal outlier, atau gunakan fungsi transformasi fitur (*winsorization* atau transformasi logaritmik log(1+x)).

C. Visualisasi Data untuk Penarikan Kesimpulan (*Data-Driven Inference*)

Visualisasi dalam konteks analitis C4 adalah sarana pembuktian matematis secara visual untuk mengambil keputusan rekayasa fitur (*feature engineering*).



1. Eksplorasi Univariat: Analisis Sebaran, Bentuk, dan Distribusi

- **Parameter Skewness (Kemencengan):**
  $\gamma_1 = [(1/N) * \Sigma(x_i - x_{mean})^3] / [(1/N) * \Sigma(x_i - x_{mean})^2]^{(3/2)}$
  - $|\gamma_1| > 1$: Kemencengan tinggi. Mengindikasikan algoritma berbasis gradient descent akan mengalami konvergensi lambat jika data tidak dinormalisasi.
  - *Tindakan Preprocessing:* Menerapkan transformasi Box-Cox ($x > 0$), Yeo-Johnson, atau transformasi log natural $\ln(x + 1)$.
- **Parameter Kurtosis (Keruncingan / Fat-Tailedness):**
  - Mengukur konsentrasi probabilitas pada bagian ekor (*tails*) distribusi.
  - Distribusi *Leptokurtik* (kurtosis ekses > 0, ekor tebal) menunjukkan bahwa model memiliki risiko tinggi menghadapi data ekstrem yang tak terduga (*black swan events*).
- **Inspeksi Multimodalitas via KDE (*Kernel Density Estimation*):**
  - Puncak kurva density ganda atau lebih mengindikasikan bahwa data merupakan gabungan dari dua atau lebih subpopulasi tersembunyi (*latent classes*). Mahasiswa diarahkan untuk memecah fitur ini menjadi klaster terpisah atau menerapkan rekayasa fitur baru (*binned feature*).

2. Eksplorasi Bivariat: Evaluasi Daya Pisah dan Asosiasi

- **Box Plot:**
  - Memeriksa *separabilitas* fitur numerik terhadap kelas target biner/multikelas.

    - Jika rentang antarkuartil (IQR) antarkelas memiliki *overlap* yang minimal, fitur tersebut memiliki daya pembeda diskriminatif (*feature importance*) yang tinggi untuk model klasifikasi.
- **Violin Plot:**
    - Menggabungkan struktur *five-number summary* dari box plot dengan estimasi densitas KDE simetris di kedua sisinya.
    - **Keunggulan Analitis dibanding Box Plot:** Mampu menyingkap distribusi multimodal dan ketidaksimetrisan lokal di dalam kelas target yang tidak terlihat pada batas-batas kuartil kotak box plot biasa.

3. Eksplorasi Multivariat: Evaluasi Multikolinearitas dan Redundansi

- **Matriks Korelasi: Memilih Metrik yang Tepat**
    - **Korelasi Pearson (r):**
      $r = \Sigma((X - \bar{X})(Y - \bar{Y})) / \sqrt{[\ \Sigma(X - \bar{X})^2 * \Sigma(Y - \bar{Y})^2\ ]}$
        - *Asumsi:* Hubungan linear murni, kedua variabel terdistribusi bivariat normal, sangat sensitif terhadap outlier.
    - **Korelasi Spearman Rank (ρ):**
      $\rho = 1 - (6 * \Sigma d_i^2) / (n * (n^2 - 1))$
        - *Asumsi:* Bersifat non-parametrik, mengukur hubungan monotonik (apakah ketika X naik, Y selalu naik, meski laju perubahannya non-linear). Resisten terhadap keberadaan pencilan.
- **Diagnosis Multikolinearitas Tinggi:**
    - **Kriteria Kritis:** Dua fitur prediktor dengan korelasi $|r| \geq 0{,}80$ atau $|\rho| \geq 0{,}80$ mengindikasikan adanya redundansi linearitas yang parah (*multicollinearity*).
    - **Dampak Matematis pada Model Machine Learning:**
        - Menyebabkan matriks kovarians (X^TX) mendekati kondisi singular (matriks mendekati non-invertibel), sehingga penghitungan bobot koefisien OLS $\hat{\beta} = (X^TX)^{-1}\ X^Ty$ menjadi numerik tidak stabil.
        - Meningkatkan *standard error* dari koefisien model linear secara drastis, sehingga nilai p-value menjadi tidak valid dan interpretasi pengaruh fitur menjadi bias.
    - **Tindakan Lanjutan Berbasis EDA:**
        - Mengeliminasi salah satu fitur yang memiliki korelasi lebih rendah terhadap label target.
        - Menggabungkan kedua fitur melalui transformasi rasio atau interaksi perkalian.
        - Menerapkan dekomposisi ortogonal via *Principal Component Analysis* (PCA) untuk mereduksi dimensi tanpa kehilangan variansi informasi.

Argumentasi I: EDA Bukan Sekadar Deskripsi Visual, Melainkan Uji Kelayakan Asumsi Matematis Algoritma

> Klaim Kritis: Memulai pemodelan prediktif tanpa validasi distribusi data melalui EDA merupakan cacat metodologis yang secara langsung menjamin terjadinya kegagalan generalisasi model.

- Penalaran:
  Banyak praktisi memperlakukan EDA secara dangkal—sebatas menampilkan ringkasan df.describe() atau membuat grafik tanpa inferensi lanjutan. Padahal, setiap algoritma *Machine Learning* dibangun di atas fondasi asumsi probabilistik yang kaku.
  - Algoritma berbasis jarak seperti K-Nearest Neighbors (KNN) atau Support Vector Machines (SVM) memperlakukan ruang fitur sebagai ruang geometris Euclidean. Jika inspeksi holistik gagal mengidentifikasi disparitas variansi antarfitur, fitur dengan magnitudo besar akan mendominasi fungsi jarak, mereduksi fitur lain menjadi tidak relevan secara artifisial.
  - Model linear dan regresi logistik mengasumsikan residu terdistribusi normal serta tidak adanya kolinearitas sempurna. Menghitung ringkasan statistik 5-angka (*five-number summary*) bukan formalitas numerik, melainkan alat pembuktian: divergensi tajam antara nilai rata-rata (*mean*) dan median membuktikan adanya kemencengan data (*skewness*). Membiarkan data yang sangat menceng masuk ke algoritma berbasis gradien (*gradient descent*) akan memperlambat konvergensi dan menghasilkan estimasi bobot parameter yang bias.
- Kesimpulan Analitis:
  EDA adalah fase pengujian hipotesis distribusi data. Keputusan menerapkan transformasi logaritmik, penskalaan (*StandardScaler* vs. *RobustScaler*), atau reduksi dimensi wajib berakar pada bukti matematis yang diperoleh dari tahapan inspeksi ini.

Argumentasi II: Anomali Data Tidak Boleh Dieliminasi Secara Seragam Tanpa Menguji Mekanisme Pembentuknya

> Klaim Kritis: Menghapus *missing values* secara otomatis (*listwise deletion*) dan membersihkan *outliers* menggunakan aturan baku tanpa memahami konteks data adalah tindakan destruktif yang merusak validitas model.

- Dilema *Missing Values* (Penghapusan vs. Imputasi):
  - Penghapusan baris hanya absah secara statistik jika data berstatus MCAR (*Missing Completely at Random*), di mana ketiadaan data terjadi murni secara acak.

    - Apabila data berstatus MAR (*Missing at Random*) atau MNAR (*Missing Not at Random*)—misalnya responden berpenghasilan sangat tinggi menolak mengisi kolom gaji—maka menghapus baris tersebut akan memotong populasi secara sistematis. Akibatnya, model tidak akan pernah belajar mengenali karakteristik segmen populasi tersebut. Pada kasus MNAR, ketiadaan nilai justru merupakan sinyal prediktif yang kuat, sehingga langkah yang benar adalah mempertahankan informasi tersebut melalui fitur indikator (*missing indicator*) sebelum menerapkan teknik imputasi berbasis model.

- Pertentangan Metodologi Deteksi *Outliers* (Z-Score vs. IQR):
    - Penggunaan Z-Score ($|Z| > 3$) bersandar pada asumsi dasar bahwa populasi terdistribusi normal (Gaussian). Namun, ketika sebuah dataset memiliki pencilan ekstrem, nilai *mean* dan *standar deviasi* itu sendiri ikut terdistorsi (*masking effect*), sehingga rumus Z-score menjadi tidak lagi valid untuk mendeteksi pencilan tersebut.
    - Sebaliknya, metode Tukey's Fences (IQR) bersifat non-parametrik dan mengandalkan kuartil yang resisten (*robust*) terhadap nilai ekstrem.
    - Lebih jauh lagi, analis level C4 harus membedakan antara *noise* (kesalahan ketik teknis) dan *natural variability*. Pada domain kritis seperti deteksi *fraud* atau prediksi anomali server, pencilan bukanlah cacat data yang harus dibuang, melainkan fokus utama pemodelan (*true positive signal*). Menghilangkannya sama dengan melenyapkan kasus yang hendak diprediksi.

Argumentasi III: Visualisasi Data Adalah Pembuktian Terstruktur untuk Mencegah Redundansi dan Kolaps Numerik

> Klaim Kritis: Grafik multivariat dan matriks korelasi bukan pelengkap laporan, melainkan garis pertahanan utama untuk mendiagnosis singularitas matriks dan multikolinearitas.

- Penalaran:
  Menilai hubungan antarvariabel secara visual bukan sekadar melihat kecenderungan naik atau turun, melainkan membedah struktur korelasi yang berpotensi merusak kestabilan model.
    - Memilih antara korelasi Pearson dan Spearman menuntut pertimbangan kritis: koefisien Pearson hanya mengukur hubungan linear murni dan sangat rapuh terhadap gangguan pencilan tunggal. Sebaliknya, korelasi Spearman mengevaluasi hubungan monotonik berdasarkan pemeringkatan peringkat (*rank*), menjadikannya instrumen yang jauh lebih valid ketika berhadapan dengan data non-linear atau data riil yang bising.
    - Ketika visualisasi *heatmap* mengungkap adanya korelasi tinggi ($|r| \geq 0{,}80$) di antara dua fitur prediktor, ini merupakan alarm kegagalan

komputasi. Dalam matematika model linear, dua variabel dengan kolinearitas tinggi menyebabkan matriks kovarians (X^TX) mendekati kondisi singular (determinan mendekati nol). Implikasinya, pembalikan matriks (*inversion*) menjadi tidak stabil secara numerik, *standard error* membengkak drastis, dan model kehilangan kemampuan memisahkan kontribusi individual dari masing-masing fitur.

- Sintesis Keputusan:
  Bukti visual multivariat memaksa analis mengambil tindakan rekayasa fitur konkret: mengeliminasi fitur yang redundan, merekayasa variabel interaksi baru, atau menerapkan ortogonalisasi fitur menggunakan *Principal Component Analysis* (PCA) guna menjaga stabilitas matematis algoritma.

10 masalah kritis dalam tahap Exploratory Data Analysis (EDA)

10 masalah kritis dalam tahap Exploratory Data Analysis (EDA) yang kerap memicu kegagalan pemodelan prediktif, lengkap dengan akar masalah, metode diagnostik analitis (C4), dan langkah penanganannya (*troubleshooting*).

1. Kebocoran Data (*Data Leakage*) Saat Eksekusi EDA dan Preprocessing

- Akar Masalah: Menghitung statistik agregat (seperti nilai *mean*, median, batas IQR, atau parameter penskalaan) menggunakan keseluruhan dataset sebelum dilakukan pemisahan (*train-test split*). Akibatnya, informasi dari data uji bocor ke data latih, menghasilkan evaluasi performa yang tampak sangat tinggi secara artifisial (*optimistic bias*) namun jeblok saat proses *deployment*.
- Diagnostik:
  - Skor metrik evaluasi pada data validasi/uji mendekati sempurna (> 99%) secara tidak wajar.
  - Terdapat disparitas performa drastis ketika model diuji pada data riil di luar proses pengujian awal.
- Troubleshooting:
  - Pisahkan dataset sejak awal: `X_train, X_test, y_train, y_test = train_test_split(...)`.
  - Hitung parameter statistik hanya pada data latih (`X_train`), lalu gunakan parameter tersebut untuk mentransformasi data uji (`X_test`).
  - Terapkan arsitektur `Pipeline` (misal dari *scikit-learn*) untuk membungkus transformasi data dan estimasi model secara terisolasi.

2. Penghapusan Baris Kosong Membabi Buta (*Listwise Deletion*) pada Data Non-Random (MAR/MNAR)

- Akar Masalah: Menggunakan perintah seperti `df.dropna()` secara seragam untuk menyelesaikan masalah *missing values*. Jika mekanisme data hilang berkorelasi dengan variabel lain (MAR) atau nilai variabel itu sendiri (MNAR),

penghapusan baris akan memotong populasi secara sistematis dan mengubah distribusi data asli.

- Diagnostik:
  - Buat matriks korelasi biner antara keberadaan nilai hilang (df.isna()) dengan fitur-fitur lainnya.
  - Gunakan uji visualisasi *nullity correlation* (via pustaka missingno). Jika indikator *missing* berkorelasi kuat dengan fitur lain, data tersebut terbukti bukan MCAR.
- Troubleshooting:
  - Jika MCAR dan proporsi data hilang < 5%, penghapusan baris masih dapat diterima.
  - Jika MAR, gunakan metode imputasi berbasis multivariat bersyarat seperti *IterativeImputer* (MICE) atau *KNNImputer*.
  - Jika MNAR, pertahankan informasi ketiadaan data dengan membuat fitur indikator biner tambahan (df['fitur_is_missing'] = df['fitur'].isna().astype(int)) sebelum melakukan imputasi nilai.

3. Masking Effect pada Deteksi Outlier Parametrik (Z-Score)

- Akar Masalah: Menguji keberadaan pencilan (*outliers*) menggunakan formula Z-Score standar (|Z| > 3) pada data yang memiliki pencilan berskala ekstrem. Rata-rata (*mean*) dan standar deviasi sangat sensitif terhadap nilai ekstrem, sehingga pencilan itu sendiri mendongkrak nilai pembagi dan "menutupi" (*masking*) keberadaan pencilan lainnya.
- Diagnostik:
  - Uji normalitas data via uji statistik formal (Shapiro-Wilk atau D'Agostino-Pearson) dan bandingkan nilai rata-rata (*mean*) terhadap median. Jika rasio perbedaannya signifikan, uji parametrik standar tidak valid.
- Troubleshooting:
  - Gunakan metode *Modified Z-score* berbasis median dan *Median Absolute Deviation* (MAD):
    M_i = [0,6745 x (x_i - x_mean)] / MAD
    dengan ambang batas anomali |M_i| > 3,5.
  - Beralih ke metode non-parametrik yang resisten terhadap pencilan: *Tukey's Fences* (IQR) dengan rentang [Q1 - 1,5 x IQR, Q3 + 1,5 x IQR].

4. Menghapus Outlier Valid pada Kasus Anomali Jarang (*True Positive Signal*)

- Akar Masalah: Menganggap semua titik data yang berada di luar rentang statistik sebagai galat (*noise*) yang harus disingkirkan. Pada domain seperti deteksi penipuan (*fraud detection*), kegagalan mesin industri, atau diagnosis penyakit kritis, pencilan tersebut justru merupakan representasi dari fenomena penting yang dicari oleh model.
- Diagnostik:

    - Periksa distribusi label target pada baris data yang teridentifikasi sebagai *outlier*.
    - Hitung proporsi kelas minoritas di dalam kelompok *outlier*. Jika persentase kelas minoritas mendominasi segmen pencilan, data tersebut membawa sinyal diskriminatif yang krusial.
- Troubleshooting:
    - Pertahankan data pencilan tersebut dalam dataset pelatihan.
    - Terapkan transformasi matematis non-linear (seperti transformasi log natural ln(1 + x) atau transformasi Yeo-Johnson) untuk mereduksi rentang nilai ekstrem tanpa menghilangkan datanya.
    - Manfaatkan model *tree-based ensemble* (misal Random Forest atau XGBoost) yang secara arsitektural kebal (*robust*) terhadap nilai pencilan.

5. Jebakan Multikolinearitas Tinggi Antarfitur Prediktor

- Akar Masalah: Membiarkan dua atau lebih variabel independen yang memiliki hubungan korelasi sangat kuat dimasukkan bersamaan ke dalam model linear/parametrik. Hal ini menyebabkan matriks kovarians (X^TX) mendekati singular (determinan mendekati nol), membuat inversi matriks tidak stabil, memicu *overfitting*, dan merusak interpretasi bobot koefisien.
- Diagnostik:
    - Visualisasikan matriks korelasi menggunakan *heatmap*.
    - Hitung nilai *Variance Inflation Factor* (VIF) untuk setiap fitur independen:
      $VIF_j = 1 / (1 - R_j^2)$
      Jika nilai VIF > 5 atau 10, fitur tersebut mengalami multikolinearitas parah.
- Troubleshooting:
    - Eliminasi satu dari pasangan variabel yang memiliki korelasi tinggi dengan mempertahankan variabel yang memiliki asosiasi paling kuat terhadap target.
    - Rekayasa fitur baru dengan menggabungkannya menjadi rasio atau indeks interaksi.
    - Gunakan reduksi dimensi seperti *Principal Component Analysis* (PCA) untuk menghasilkan komponen ortogonal yang saling independen.

6. Bias Asumsi Linearitas Menggunakan Korelasi Pearson untuk Hubungan Non-Linear

- Akar Masalah: Hanya mengandalkan koefisien korelasi Pearson (r) untuk menyeleksi fitur. Pearson hanya mengukur derajat hubungan linear lurus. Hubungan fungsional non-linear (seperti fungsi kuadratik, eksponensial, atau pola kurva U terbalik) akan menghasilkan nilai $r \approx 0$, sehingga analis keliru membuang fitur yang sebenarnya memiliki daya prediksi kuat.
- Diagnostik:

    - Buat diagram sebar (*scatter plot*) bivariat antara fitur prediktor dengan variabel target alih-alih hanya membaca tabel matriks korelasi.
    - Bandingkan nilai koefisien korelasi Pearson dengan korelasi peringkat Spearman atau Kendall Tau.
- Troubleshooting:
    - Gunakan metrik korelasi non-parametrik monotonik (Spearman Rank Correlation).
    - Evaluasi ketergantungan non-linear menggunakan metrik berbasis teori informasi seperti *Mutual Information* (mutual_info_classif atau mutual_info_regression).
    - Tambahkan transformasi polinomial atau *spline* pada fitur tersebut agar hubungan non-linear dapat ditangkap oleh model linear.

7. Pengabaian Multimodalitas Fitur (Adanya Subpopulasi Tersembunyi)

- Akar Masalah: Memperlakukan variabel kontinu seolah-olah memiliki distribusi tunggal hanya karena rentang nilainya kontinu. Jika kurva distribusi memiliki puncak ganda (*bimodal* atau *multimodal*), penggunaan nilai tendensi sentral (seperti *mean* atau median global) akan meleset dari kondisi sebenarnya karena data berasal dari beberapa subkelompok tersembunyi.
- Diagnostik:
    - Plot visualisasi estimasi densitas kernel (*Kernel Density Estimation* / KDE) atau histogram dengan jumlah *bins* yang memadai.
    - Deteksi keberadaan lebih dari satu puncak lokal pada kurva distribusi fitur.
- Troubleshooting:
    - Urai variabel dengan melakukan analisis bivariat terhadap variabel kategorikal yang ada untuk mengetahui faktor pemisah subpopulasi tersebut.
    - Buat fitur kategorikal baru berbasis interval pengelompokan (*binning* atau diskretisasi).
    - Terapkan algoritma *clustering* (seperti Gaussian Mixture Models) untuk mengekstrak identitas klaster sebagai fitur tambahan.

8. Penskalaan Fitur yang Salah Sasaran pada Data Menceng Ekstrem (*Skewed*)

- Akar Masalah: Menerapkan standardisasi Z-score (*StandardScaler*) secara otomatis pada data yang memiliki kemencengan (*skewness*) ekstrem. *StandardScaler* mempertahankan bentuk distribusi asli; jika data aslinya sangat menceng, data hasil transformasi tetap menceng dan rentang nilainya tetap terdistorsi oleh titik-titik ekstrem.
- Diagnostik:
    - Hitung koefisien kemencengan Fisher-Pearson ($\gamma 1$). Jika $|\gamma 1| > 1$, data dikategorikan sangat menceng (*highly skewed*).
    - Bandingkan bentuk histogram sebelum dan sesudah proses penskalaan dilakukan.

- Troubleshooting:
    - Terapkan transformasi penstabil variansi terlebih dahulu sebelum penskalaan, seperti transformasi logaritmik log(x + 1), Box-Cox (untuk data positif), atau Yeo-Johnson.
    - Gunakan *RobustScaler* yang menggunakan median dan rentang interkuartil (IQR) sebagai dasar pergeseran dan penskalaan data, sehingga tahan terhadap gangguan pencilan.

9. Paradoks Akurasi Akibat Pengabaian Rasio Ketidakseimbangan Kelas (*Class Imbalance*)

- Akar Masalah: Tidak memeriksa distribusi frekuensi relatif kelas target pada kasus klasifikasi saat tahap univariat EDA. Analis berasumsi model bekerja dengan baik saat melihat metrik *accuracy* tinggi, padahal model hanya memprediksi kelas mayoritas secara monoton (*majority class predictor*).
- Diagnostik:
    - Hitung rasio perbandingan kelas target:
      Imbalance Ratio = N_mayoritas / N_minoritas
    - Jika rasio melampaui 4:1 atau bahkan 100:1, metrik akurasi standar sudah kehilangan validitasnya.
- Troubleshooting:
    - Jangan gunakan *Accuracy* sebagai tolok ukur evaluasi; beralih ke *Precision-Recall AUC* (PR-AUC), F1-Score, atau *Balanced Accuracy*.
    - Terapkan strategi penyeimbangan sampel pada data latih seperti *oversampling* sintetis (SMOTE / ADASYN) atau penyesuaian bobot penalti algoritma (*class_weight='balanced'*).
    - Pastikan proses pembagian data menggunakan teknik berstrata (*stratified splitting* atau *StratifiedKFold*) agar proporsi kelas tetap konsisten.

10. Fitur Identitas Unik Berkardinalitas Tinggi Disangka Prediktor Kuat

- Akar Masalah: Membiarkan kolom pengenal unik (seperti User_ID, Transaction_ID, atau nomor faktur) masuk ke dalam matriks fitur karena terlihat berkorelasi semu atau menghasilkan nilai *feature importance* yang tinggi pada algoritma *decision tree*. Fitur semacam ini hanya merekam urutan data latih, bukan pola general yang dapat diterapkan pada data baru.
- Diagnostik:
    - Hitung rasio kardinalitas unik terhadap total baris data:
      Uniqueness Ratio = Jumlah Nilai Unik / N
      Jika nilai rasio mendekati 1,0 pada tipe data non-numerik teks atau identitas, fitur tersebut adalah pengenal unik.
- Troubleshooting:
    - Lakukan penghapusan (*drop*) terhadap kolom identitas unik sebelum proses pelatihan model.

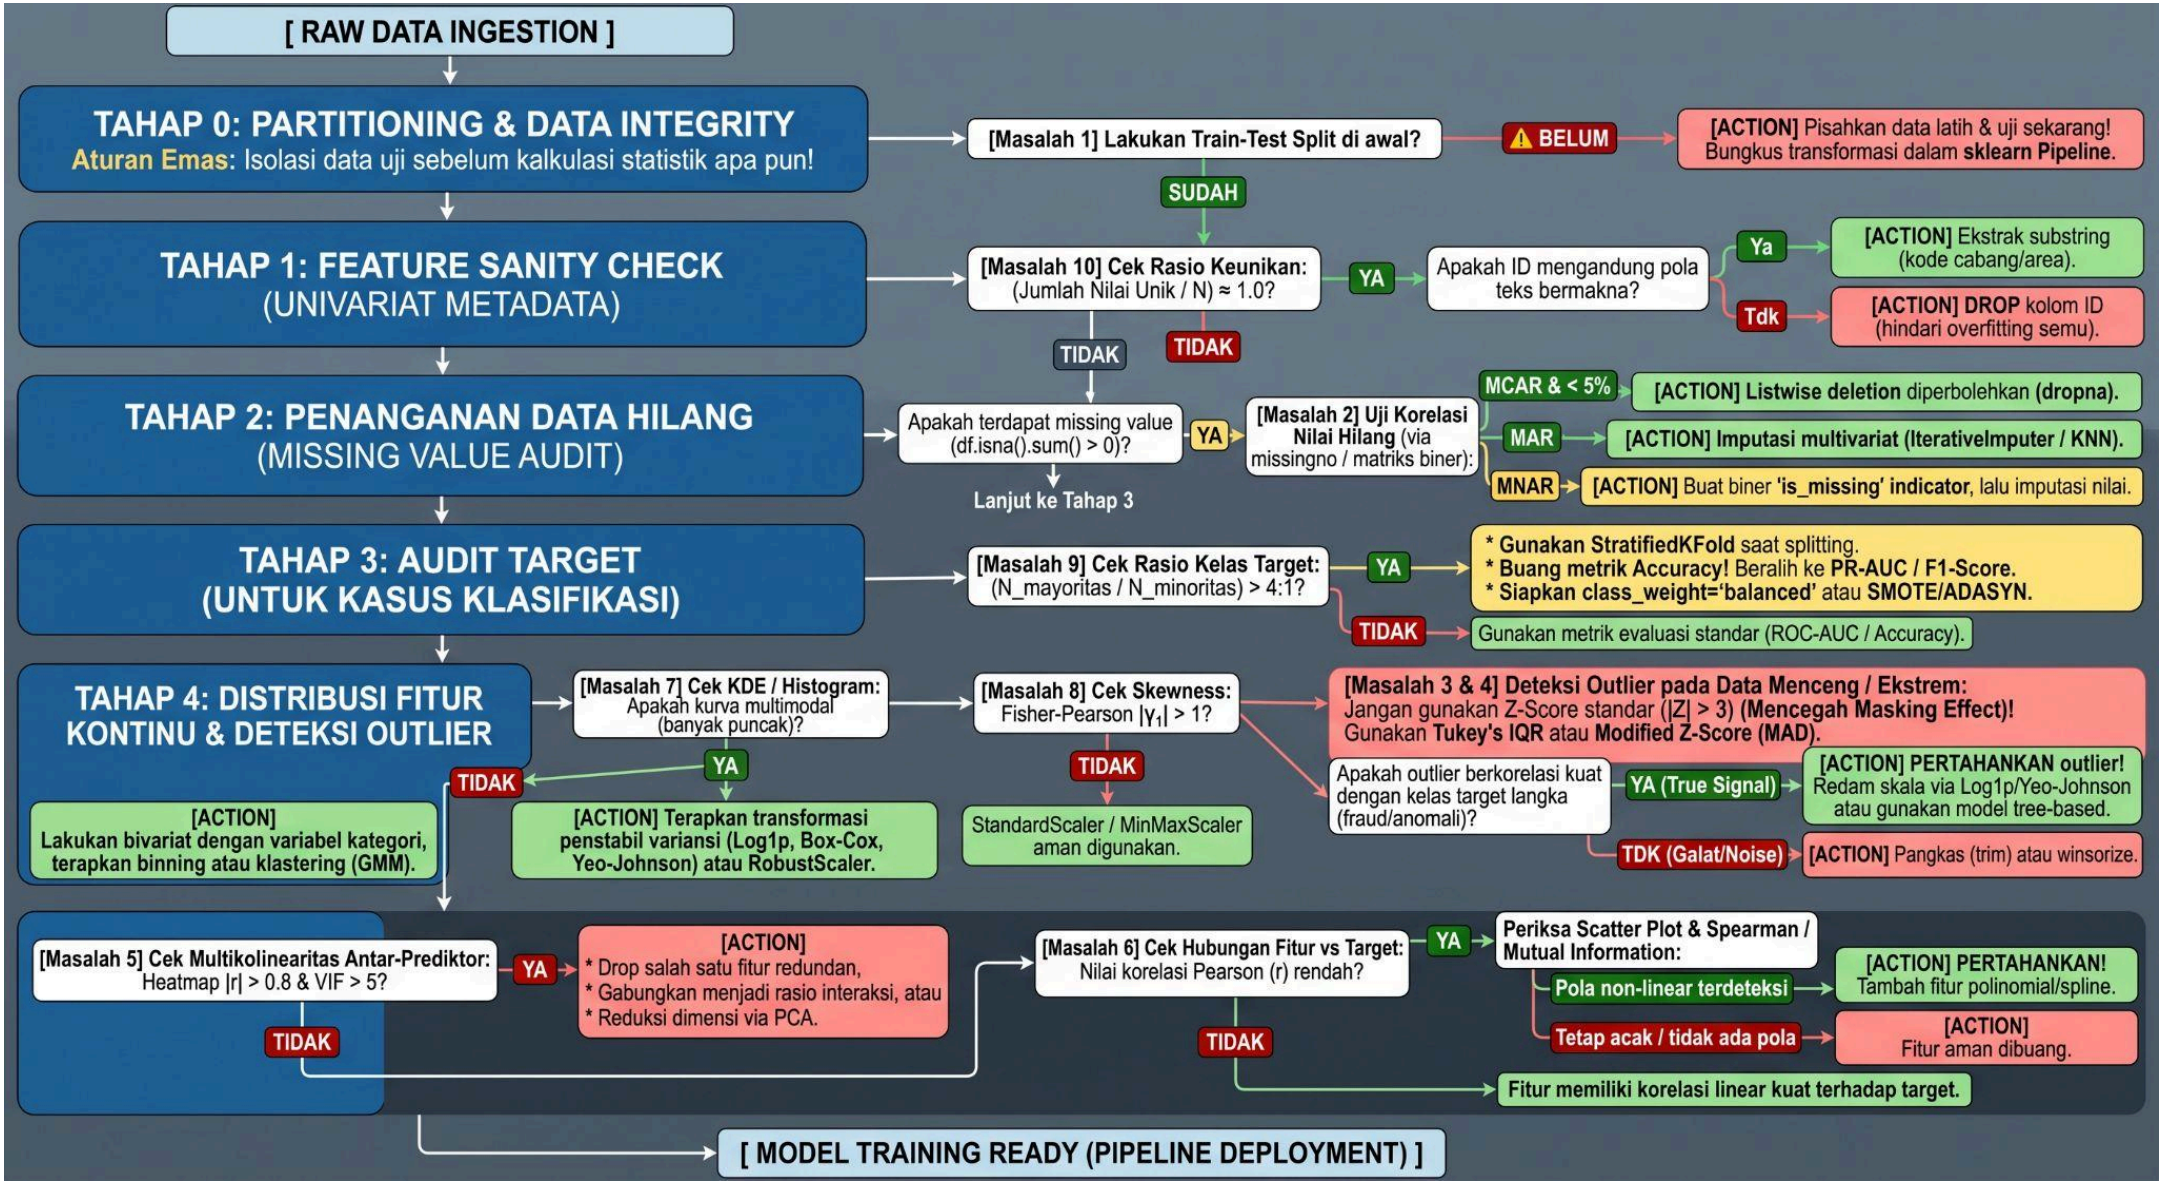
- Jika kolom tersebut mengandung struktur teks yang membawa konteks (misal awalan kode pos atau kode cabang bisnis), lakukan rekayasa fitur dengan mengekstrak pola string tersebut menjadi entitas kategorikal baru dengan kardinalitas yang wajar.

Matriks Ringkasan Diagnostik EDA

No	Gejala Kegagalan Model	Akar Masalah EDA	Tindakan Korektif (Troubleshooting)
1	Evaluasi validasi sempurna tapi gagal di produksi	Kebocoran data (*Data Leakage*) sebelum split	Terapkan *train-test split* di awal dan gunakan arsitektur Pipeline.
2	Performa model bias pada segmen tertentu	*Listwise deletion* sembarangan pada data non-random	Identifikasi mekanisme (MCAR/MAR/MNAR) dan gunakan imputasi terarah / *missing indicator*.
3	Pencilan ekstrem gagal terdeteksi	*Masking effect* akibat penggunaan Z-score standar	Gunakan metode non-parametrik (IQR / *Tukey's Fences*) atau *Modified Z-Score*.
4	Model gagal memprediksi anomali langka (*fraud*)	Menghapus pencilan valid (*true signals*)	Pertahankan pencilan, gunakan model *tree-based*, atau transformasi logaritmik.
5	Koefisien model linear tidak stabil / nilai p-value rancu	Multikolinearitas tinggi ($\|r\| \geq 0{,}80$)	Hitung nilai VIF, eliminasi fitur redundan, atau terapkan PCA.
6	Fitur potensial terbuang karena korelasi rendah	Mengukur asosiasi non-linear hanya via korelasi Pearson	Evaluasi diagram sebar, gunakan korelasi Spearman atau *Mutual Information*.
7	Estimasi nilai tengah meleset pada fitur kontinu	Mengabaikan distribusi multimodal	Deteksi via visualisasi KDE, lakukan rekayasa fitur berbasis klaster atau *binning*.

8	Konvergensi model berbasis jarak / gradien lambat	Menggunakan *StandardScaler* pada data menceng	Terapkan transformasi penstabil variansi (Box-Cox / Yeo-Johnson) atau *RobustScaler*.
9	Model bias memprediksi kelas mayoritas	Mengabaikan ketidakseimbangan kelas target	Evaluasi menggunakan PR-AUC/F1-Score dan gunakan *StratifiedKFold* serta *class weight*.
10	*Overfitting* ekstrem pada data latih	Memasukkan fitur kardinalitas ekstrem / ID unik	Evaluasi rasio keunikan fitur, hapus identitas unik, atau ekstrak pola kodenya.

KLIK UNTUK VERSI RESOLUSI TINGGI



STANDAR OPERASIONAL PROSEDUR (SOP)

PANDUAN KEPUTUSAN EDA & PREPROCESSING PIPELINE MACHINE LEARNING

Prinsip Utama (Golden Rule):

Isolasi data uji (*test set*) sebelum melakukan kalkulasi statistik agregat apa pun guna mencegah kebocoran data (*data leakage*).

TAHAP 0: PARTITIONING & DATA INTEGRITY

- **Fokus Masalah:** [M1] Pencegahan Data Leakage
- **Pemeriksaan:** Apakah *train-test split* sudah dilakukan di awal sebelum agregasi data?
    - **Belum:**
        - **Tindakan Korektif:**
            1. Pisahkan dataset segera: X_train, X_test, y_train, y_test = train_test_split(...).
            2. Hitung statistik hanya pada data latih (X_train).
            3. Bungkus seluruh rantai transformasi ke dalam Pipeline Scikit-Learn.
    - **Sudah:** Lanjut ke Tahap 1.

TAHAP 1: FEATURE SANITY CHECK (UNIVARIAT METADATA)

- **Fokus Masalah:** [M10] Fitur Kardinalitas Tinggi / ID Unik
- **Pemeriksaan:** Apakah rasio keunikan (Jumlah Nilai Unik / N) ≈ 1,0?
    - **Ya (Terindikasi ID Unik):**
        - *Apakah string memiliki pola kontekstual bermakna?*
            - **Ya:** Ekstrak pola teks menjadi fitur kategorikal baru (misal: kode cabang, wilayah, atau tanggal transaksi).
            - **Tidak:** Hapus (*drop*) kolom ID agar model tidak mengalami *overfitting* semu.
    - **Tidak:** Pertahankan fitur, lanjut ke Tahap 2.

TAHAP 2: PENANGANAN DATA HILANG (MISSING VALUE AUDIT)

- **Fokus Masalah:** [M2] Audit Nilai Hilang Non-Random
- **Pemeriksaan Awal:** Apakah terdapat nilai kosong (df.isna().sum() > 0)?
    - **Tidak:** Lanjut ke Tahap 3.
    - **Ya:** Evaluasi korelasi ketidakhadiran (*missingness mechanism*):
        - **MCAR (*Missing Completely at Random*) & proporsi < 5%:**
            - **Tindakan:** Penghapusan baris diperbolehkan (dropna()).
        - **MAR (*Missing at Random*):**
            - **Tindakan:** Imputasi multivariat bersyarat menggunakan IterativeImputer (MICE) atau KNNImputer.
        - **MNAR (*Missing Not at Random*):**

        - **Tindakan:** Buat fitur indikator biner tambahan terlebih dahulu (is_missing = 1/0), baru terapkan imputasi berbasis model.

TAHAP 3: AUDIT TARGET (KLASIFIKASI)

- **Fokus Masalah:** [M9] Ketidakseimbangan Kelas Ekstrem (*Class Imbalance*)
- **Pemeriksaan:** Apakah rasio ketidakseimbangan kelas target (N_mayoritas / N_minoritas) > 4:1?
    - **Ya:**
        - **Tindakan Wajib:**
            1. Terapkan validasi silang berstrata (StratifiedKFold).
            2. Ganti metrik evaluasi dari *Accuracy* ke **PR-AUC**, **F1-Score**, atau **Balanced Accuracy**.
            3. Pasang parameter pembobotan class_weight='balanced' pada model atau lakukan *resampling* terarah (SMOTE/ADASYN).
    - **Tidak:**
        - **Tindakan:** Gunakan metrik evaluasi standar (*Accuracy*, ROC-AUC).

TAHAP 4: DISTRIBUSI FITUR KONTINU & DETEKSI OUTLIER

- **Pemeriksaan Bentuk Kurva:** [M7] Multimodalitas
    - *Apakah kurva KDE/histogram memiliki lebih dari satu puncak?*
        - **Ya:** Lakukan analisis bivariat terhadap fitur kategori, lalu terapkan *binning* interval atau *clustering* (GMM).
        - **Tidak:** Lanjut ke pengujian kemencengan.
- **Pemeriksaan Kemencengan (*Skewness*):** [M8] Penskalaan Fitur Menceng
    - *Apakah nilai absolut koefisien kemencengan $|\gamma 1| > 1$?*
        - **Ya:** Terapkan transformasi penstabil variansi (Log1p, Box-Cox, atau Yeo-Johnson), atau gunakan RobustScaler.
        - **Tidak:** Aman menggunakan StandardScaler atau MinMaxScaler.
- **Pemeriksaan Pencilan (*Outliers*):** [M3 & M4]
    - **Catatan Diagnostik:** Hindari Z-score standar (|Z| > 3) untuk mencegah *masking effect*. Gunakan **Tukey's IQR** atau **Modified Z-Score (MAD)**.
    - *Apakah pencilan berkorelasi kuat dengan kelas target langka (kasus fraud/anomali)?*
        - **Ya (*True Signal*): Pertahankan pencilan!** Redam skalanya via Log1p atau gunakan model berbasis pohon (*tree-based*).
        - **Tidak (*Noise* / Galat):** Pangkas (*trimming*) atau lakukan *winsorizing*.

TAHAP 5: ASOSIASI & SELEKSI FITUR

- **Pemeriksaan Multikolinearitas:** [M5] Ketergantungan Linear Antar-Prediktor
    - *Apakah korelasi antarprediktor $|r| > 0{,}8$ dan nilai VIF > 5?*

        - **Ya:** Hapus salah satu fitur redundan, lebur menjadi fitur rasio/indeks interaksi, atau terapkan PCA.
        - **Tidak:** Pertahankan pasangan fitur.
- **Pemeriksaan Relasi Prediktor vs Target:** [M6] Bias Asumsi Linearitas
    - *Apakah koefisien korelasi Pearson (r) terhadap target bernilai rendah?*
        - **Ya:** Evaluasi *scatter plot* dan metrik non-linear (*Spearman* / *Mutual Information*):
            - *Terdeteksi pola non-linear:* **Pertahankan fitur!** Tambahkan fitur polinomial atau *spline*.
            - *Murni acak tanpa pola:* Fitur aman untuk dieliminasi (*drop*).
        - **Tidak:** Fitur prediktor linear valid untuk digunakan.

MATRIKS RINGKASAN TINDAKAN CEPAT

Tahap	Pemeriksaan Utama	Ambang Batas Kritis	Tindakan Utama
0. Partitioning	Posisi *train-test split*	Sebelum kalkulasi statistik apa pun	Split X/y dan gunakan *pipeline*
1. Sanity Check	Rasio keunikan kolom	≈ 1,0	Drop kolom ID atau ekstrak kode pola
2. Missing Values	Pola data hilang	MCAR / MAR / MNAR	Drop baris (MCAR < 5%), KNN (MAR), Indikator biner (MNAR)
3. Target Audit	Rasio kelas target	Rasio > 4:1	StratifiedKFold, evaluasi PR-AUC/F1, class_weight

4. Distribusi	Skewness & tipe outlier	|γ1| > 1 & *true signal* vs *noise*	Transformasi logaritmik, pertahankan pencilan sinyal langka
5. Seleksi Fitur	Multikolinearitas & non-linearitas	VIF > 5 & korelasi non-linear	Drop fitur ganda, gunakan *Mutual Information*

Status Pipeline: Selesai, dataset tervalidasi dan siap masuk ke proses pelatihan model (*Model Training Ready*).

Berikut adalah studi kasus terstruktur penerapan **5 Tahap EDA & Preprocessing Pipeline** pada dataset **Give Me Some Credit (Kaggle)**, lengkap dengan landasan analisis, kode eksekusi Python, serta interpretasi hasilnya.

Gambaran Singkat Dataset

- **Target (y):** SeriousDlqin2yrs (1 = menunggak pinjaman ≥ 90 hari dalam 2 tahun; 0 = lancar).
- **Prediktor (X):** 10 fitur finansial & demografis (antara lain RevolvingUtilizationOfUnsecuredLines, age, MonthlyIncome, DebtRatio, dan 3 kolom frekuensi tunggakan).
- **Jumlah Observasi:** 150.000 baris data latih (cs-training.csv). https://www.kaggle.com/datasets/carolline89/cs-training
- Data Testing : https://github.com/JLZml/Credit-Scoring-Data-Sets/blob/master/3.%20Kaggle/Give%20Me%20Some%20Credit/cs-test.csv

TAHAP 0: Partitioning & Data Integrity

1. Landasan & Analisis Masalah [M1]

Pencegahan *data leakage* menuntut pemisahan data dilakukan **sebelum** menghitung median, mean, kuartil IQR, atau parameter penskalaan apa pun. Jika imputasi atau scaling dijalankan pada seluruh dataframe (df), statistik data uji akan bocor ke data latih, memicu *optimistic evaluation bias*.

2. Implementasi Kode

Python

```python
import pandas as pd
from sklearn.model_selection import train_test_split

# Memuat data
df = pd.read_csv('cs-training.csv')

# Memisahkan target dan prediktor
X = df.drop(columns=['SeriousDlqin2yrs'])
y = df['SeriousDlqin2yrs']

# Eksekusi partisi di awal dengan stratifikasi label
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

TAHAP 1: Feature Sanity Check (Univariat Metadata)

1. Landasan & Analisis Masalah [M10]

Dataset Kaggle ini memiliki kolom indeks bawaan bernama Unnamed: 0 yang merepresentasikan nomor baris rekaman nasabah.

Uniqueness Ratio = Jumlah Nilai Unik / N = 120.000 / 120.000 = 1,0
Fitur ini murni penomoran berurutan tanpa struktur kontekstual (bukan kode cabang atau timestamp). Jika dibiarkan, algoritma pohon (*decision tree*) dapat membelah (*split*) node berdasarkan ID unik tersebut dan mengalami *overfitting* semu.

2. Implementasi Kode

Python

```python
# Evaluasi rasio keunikan
uniqueness_ratio = X_train.nunique() / len(X_train)
print("Fitur dengan Uniqueness Ratio mendekati 1.0:\n",
uniqueness_ratio[uniqueness_ratio > 0.99])

# Tindakan: Drop kolom ID unik
X_train = X_train.drop(columns=['Unnamed: 0'], errors='ignore')
X_test = X_test.drop(columns=['Unnamed: 0'], errors='ignore')
```

TAHAP 2: Penanganan Data Hilang (Missing Value Audit)

1. Landasan & Analisis Masalah [M2]

Audit pada X_train menunjukkan dua fitur memiliki nilai kosong:

- NumberOfDependents: sekitar 2,6% baris kosong (cenderung MCAR/MAR).
- MonthlyIncome: sekitar 19,8% baris kosong.

Pada MonthlyIncome, mekanisme ketidakhadiran adalah **MNAR (*Missing Not at Random*)**: nasabah yang tidak berpenghasilan, berstatus pengangguran, atau berpenghasilan informal cenderung menolak melaporkan pemasukan. Menghapus baris via dropna() akan membuang 20% populasi secara bias. Mengisinya langsung dengan median tanpa tanda akan menghapus sinyal bahwa nasabah sengaja menyembunyikan profil keuangannya.

2. Implementasi Kode

Python

```python
from sklearn.impute import SimpleImputer
from sklearn.compose import ColumnTransformer
```

```
from sklearn.pipeline import Pipeline

# 1. Diagnostik korelasi missingness
is_missing_income = X_train['MonthlyIncome'].isna().astype(int)
print("Tingkat default pada Income kosong vs terisi:")
print(y_train.groupby(is_missing_income).mean())
# Hasil: Kelompok missing income punya tingkat default signifikan
berbeda!

# 2. Pipeline Imputasi: Tambahkan indikator biner untuk MNAR
income_imputer = Pipeline([
    ('impute_mnar', SimpleImputer(strategy='median',
add_indicator=True))
])

dependents_imputer = Pipeline([
    ('impute_mar', SimpleImputer(strategy='median',
add_indicator=False))
])
```

TAHAP 3: Audit Target (Klasifikasi)

1. Landasan & Analisis Masalah [M9]

Pemeriksaan frekuensi kelas pada y_train:

- Kelas 0 (Lancar): sekitar 93,3%
- Kelas 1 (Gagal Bayar): sekitar 6,7%
- Imbalance Ratio = 93,3 / 6,7 ≈ 13,9 : 1 (jauh melampaui batas 4:1).

Jika menggunakan metrik *Accuracy*, model naif yang selalu menebak "Lancar" akan memperoleh skor 93,3% namun gagal mendeteksi 100% kasus kredit macet.

2. Implementasi Keputusan

- **Validasi Silang:** Wajib menggunakan StratifiedKFold(n_splits=5).
- **Metrik Evaluasi:** Menggunakan **PR-AUC (Precision-Recall AUC)** dan **F1-Score makro** sebagai kompas utama.
- **Strategi Model:** Pasang class_weight='balanced' atau parameter penalti rasio skala (misalnya scale_pos_weight=13.9 pada XGBoost).

Python

```
from sklearn.model_selection import StratifiedKFold
```

```
from sklearn.metrics import precision_recall_curve, auc,
classification_report

cv_strategy = StratifiedKFold(n_splits=5, shuffle=True,
random_state=42)
# Bobot penalti: N_negatif / N_positif ≈ 13.9
scale_weight = (y_train == 0).sum() / (y_train == 1).sum()
```

- **Validasi Silang:** Wajib menggunakan StratifiedKFold(n_splits=5).
- **Metrik Evaluasi:** Menggunakan **PR-AUC (Precision-Recall AUC)** dan **F1-Score makro** sebagai kompas utama.
- **Strategi Model:** Pasang class_weight='balanced' atau parameter penalti rasio skala (misalnya scale_pos_weight=13.9 pada XGBoost).

TAHAP 4: Distribusi Fitur Kontinu & Deteksi Outlier

1. Landasan & Analisis Masalah

- **Multimodalitas [M7]:** Fitur keterlambatan bayar (NumberOfTime30-59DaysPastDueNotWorse, NumberOfTimes90DaysLate) memiliki nilai diskrit berkumpul di angka 0, 1, 2, serta anomali spike di angka 96 dan 98 (kode eror sistem perbankan lama). Perlu dikelompokkan (*binning*).
- **Skewness [M8]:** Fitur RevolvingUtilizationOfUnsecuredLines dan DebtRatio memiliki nilai kemencengan Fisher-Pearson $|\gamma 1| >> 10$. Penggunaan StandardScaler akan merusak bobot gradien. Solusinya adalah **RobustScaler** atau transformasi log(1 + x).
- **Audit Outlier [M3 & M4]:**
  - Deteksi berbasis Z-Score gagal karena nilai utilisasi ekstrem mendongkrak standar deviasi (*masking effect*). Digunakan rentang **Tukey's IQR** atau **Modified Z-score**.
  - **Uji True Signal:** Nasabah dengan saldo kredit melampaui limit (RevolvingUtilization > 2,0) dan rasio utang tinggi memiliki proporsi gagal bayar > 40% (jauh di atas rata-rata populasi 6,7%). Ini adalah **true positive signal**. Data **tidak boleh dibuang**, melainkan diskalakan secara robust.

2. Implementasi Kode

Python

```
import numpy as np
from sklearn.preprocessing import RobustScaler,
FunctionTransformer
```

```
# Log-transform untuk meredam skewness tanpa menghilangkan relasi ordinal
log_transformer = FunctionTransformer(np.log1p, validate=True)

# Penskalaan tahan pencilan
robust_scaler = RobustScaler()
```

TAHAP 5: Asosiasi & Seleksi Fitur

1. Landasan & Analisis Masalah

- **Multikolinearitas [M5]:**
  Tiga variabel keterlambatan bayar saling memiliki korelasi kuat (r > 0,85 dan VIF > 8):
  1. NumberOfTime30-59DaysPastDueNotWorse
  2. NumberOfTime60-89DaysPastDueNotWorse
  3. NumberOfTimes90DaysLate
- *Tindakan:* Daripada membiarkan ketiganya merusak stabilitas koefisien, buat satu fitur agregat baru: TotalPastDue = F1 + F2 + F3, atau reduksi dimensinya.
- **Non-Linearitas [M6]:**
  Variabel age memiliki korelasi Pearson linier mendekati nol (r ≈ -0,11) terhadap target. Namun pengujian bivariat dan *Mutual Information* membuktikan relasi kurva berbentuk U-terbalik: nasabah sangat muda (< 25 tahun) dan lansia berisiko lebih rendah dibanding usia produktif menengah yang menanggung beban cicilan tinggi.
  Tindakan: Jangan drop fitur age. Gunakan model berbasis pohon (*non-linear decision boundaries*) atau tambahkan pembagian kelompok usia (*age binning*).

Struktur Utuh Pipeline Pra-Pemodelan (Scikit-Learn)

Berikut penyatuan hasil audit ke dalam satu arsitektur terintegrasi yang siap dilatih:

Python

```
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import RobustScaler
from xgboost import XGBClassifier

# Definisi kelompok kolom
```

```
num_features_skewed = ['RevolvingUtilizationOfUnsecuredLines',
'DebtRatio']
num_features_income = ['MonthlyIncome']
num_features_general = ['age', 'NumberOfDependents',
'NumberOfOpenCreditLinesAndLoans',
'NumberRealEstateLoansOrLines']
col_past_due = ['NumberOfTime30-59DaysPastDueNotWorse',
'NumberOfTimes90DaysLate',
'NumberOfTime60-89DaysPastDueNotWorse']

# Pipeline pra-pemrosesan terpadu
preprocessor = ColumnTransformer(transformers=[
    # M8 & M4: Redam skala fitur skewed ekstrem
    ('skewed', Pipeline([
        ('impute', SimpleImputer(strategy='median')),
        ('scaler', RobustScaler())
    ]), num_features_skewed),

    # M2: Imputasi MNAR dengan missing indicator otomatis
    ('income', SimpleImputer(strategy='median',
add_indicator=True), num_features_income),

    # Fitur numerik umum
    ('general', Pipeline([
        ('impute', SimpleImputer(strategy='median')),
        ('scaler', RobustScaler())
    ]), num_features_general),

    # Fitur tunggakan
    ('past_due', SimpleImputer(strategy='median'), col_past_due)
])

# Gabungkan dengan Estimator yang kebal outlier (Tree-based) dan
mengatasi Imbalance
model_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('classifier', XGBClassifier(
        scale_pos_weight=scale_weight, # M9: Penyeimbang kelas
        random_state=42,
```

```
        eval_metric='aucpr'           # Evaluasi fokus PR-AUC
    ))
])

# Melatih model secara terisolasi tanpa risiko kebocoran data
(M1)
model_pipeline.fit(X_train, y_train)

# Prediksi pada data uji yang bersih
y_pred_proba = model_pipeline.predict_proba(X_test)[:, 1]
precision, recall, _ = precision_recall_curve(y_test,
y_pred_proba)
print("Final PR-AUC Score:", auc(recall, precision))
```

Berikut adalah skrip Python lengkap menggunakan matplotlib, seaborn, dan statsmodels untuk mendiagnosis:

1. **Kurva KDE & Uji Skewness** (membandingkan distribusi asli vs hasil transformasi log(1+x)).
2. **Heatmap Matriks Korelasi & Tabel VIF** (mendeteksi redundansi linear antarkolom keterlambatan bayar).

Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import skew
from statsmodels.stats.outliers_influence import
variance_inflation_factor

#
------------------------------------------------------------------
--------
```

```
# 1. SETUP DATA (X_train hasil split Tahap 0 & Tahap 1)
#
--------------------------------------------------------------------
--------
# Load data & drop ID unik (Tahap 1)
df = pd.read_csv('cs-training.csv')
if 'Unnamed: 0' in df.columns:
    df = df.drop(columns=['Unnamed: 0'])

# Kolom prediktor numerik utama
features = [
    'RevolvingUtilizationOfUnsecuredLines',
    'age',
    'NumberOfTime30-59DaysPastDueNotWorse',
    'DebtRatio',
    'MonthlyIncome',
    'NumberOfOpenCreditLinesAndLoans',
    'NumberOfTimes90DaysLate',
    'NumberRealEstateLoansOrLines',
    'NumberOfTime60-89DaysPastDueNotWorse',
    'NumberOfDependents'
]

# Imputasi median sementara hanya untuk kebutuhan kalkulasi VIF &
visualisasi
df_clean = df[features].copy()
df_clean = df_clean.fillna(df_clean.median())

#
--------------------------------------------------------------------
--------
# 2. DIAGNOSTIK SKEWNESS & MULTIMODALITAS (KDE PLOT)
#
--------------------------------------------------------------------
--------
skewed_cols = ['RevolvingUtilizationOfUnsecuredLines',
'DebtRatio', 'MonthlyIncome']

fig, axes = plt.subplots(len(skewed_cols), 2, figsize=(14, 10))
```

```
fig.suptitle('Diagnostik Skewness: Distribusi Asli vs
Transformasi Log(1+x)', fontsize=14, fontweight='bold')

for idx, col in enumerate(skewed_cols):
    data_orig = df_clean[col]
    skew_orig = skew(data_orig)

    # Visualisasi Data Asli (dibatasi persentil 99 agar plot
terbaca & terhindar dari outlier ekstrem visual)
    p99 = np.percentile(data_orig, 99)
    sns.kdeplot(data_orig[data_orig <= p99], ax=axes[idx, 0],
color='#d9534f', fill=True, alpha=0.4)
    axes[idx, 0].set_title(f'{col} (Asli)\nSkewness
Fisher-Pearson: {skew_orig:.2f}', fontsize=10)
    axes[idx, 0].set_xlabel('Nilai')
    axes[idx, 0].set_ylabel('Densitas')

    # Visualisasi Setelah Log1p Transform
    data_log = np.log1p(data_orig[data_orig >= 0])
    skew_log = skew(data_log)
    sns.kdeplot(data_log, ax=axes[idx, 1], color='#0275d8',
fill=True, alpha=0.4)
    axes[idx, 1].set_title(f'{col} (Log1p Transform)\nSkewness
Reduksi: {skew_log:.2f}', fontsize=10)
    axes[idx, 1].set_xlabel('log(1 + x)')
    axes[idx, 1].set_ylabel('Densitas')

plt.tight_layout()
plt.show()

#
----------------------------------------------------------------
--------
# 3. DIAGNOSTIK MULTIKOLINEARITAS (HEATMAP & VIF)
#
----------------------------------------------------------------
--------
# Fokus pada fitur keterlambatan bayar yang rawan kolinearitas
tinggi
```

```
past_due_cols = [
    'NumberOfTime30-59DaysPastDueNotWorse',
    'NumberOfTimes90DaysLate',
    'NumberOfTime60-89DaysPastDueNotWorse',
    'NumberOfOpenCreditLinesAndLoans',
    'NumberRealEstateLoansOrLines'
]

X_vif_df = df_clean[past_due_cols]

# Hitung Variance Inflation Factor (VIF)
vif_data = pd.DataFrame()
vif_data['Feature'] = X_vif_df.columns
vif_data['VIF'] = [
    variance_inflation_factor(X_vif_df.values, i)
    for i in range(X_vif_df.shape[1])
]
vif_data = vif_data.sort_values(by='VIF',
ascending=False).reset_index(drop=True)

# Plot Heatmap Korelasi Pearson berdampingan dengan Tabel VIF
fig, (ax_heat, ax_table) = plt.subplots(1, 2, figsize=(15, 5),
gridspec_kw={'width_ratios': [1.3, 1]})

# Heatmap
corr_matrix = X_vif_df.corr(method='pearson')
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
sns.heatmap(corr_matrix, annot=True, fmt='.2f', cmap='Blues',
vmin=-1, vmax=1,
            mask=mask, ax=ax_heat, cbar_kws={'label': 'Korelasi
Pearson (r)'})
ax_heat.set_title('Heatmap Korelasi Linear Antarfitur',
fontsize=12, fontweight='bold')

# Tabel VIF Barplot
palette = ['#d9534f' if val > 5 else '#5cb85c' for val in
vif_data['VIF']]
sns.barplot(data=vif_data, x='VIF', y='Feature', palette=palette,
ax=ax_table)
```

```
ax_table.axvline(x=5, color='orange', linestyle='--',
label='Batas Toleransi (VIF = 5)')
ax_table.axvline(x=10, color='red', linestyle='--',
label='Multikolinearitas Parah (VIF = 10)')
ax_table.set_title('Nilai Variance Inflation Factor (VIF)',
fontsize=12, fontweight='bold')
ax_table.set_xlabel('Nilai VIF')
ax_table.legend(loc='lower right')

plt.tight_layout()
plt.show()

# Print ringkasan numerik VIF
print("\n--- RINGKASAN SKOR VIF ---")
print(vif_data.to_string(index=False))
```